Video2Action：共享控制空间科研汇报讲稿

建议时长约21分钟，含开场视频展示。正文顺序对应网页14节：pipeline、overfit、data、vision、latent、training、ablations、root、generalization、metrics、efficiency、retarget、extensions、resources。方括号为演示动作，不口播。实验数值快照为2026年11月6日；外部验证和效率以网页标注时间及实际完成分母为准。

开场视频：先看训练之外的动作（60–90秒）

[打开页面顶部的8段视频展区，默认双列。先播放挥手、交替抬臂和屈膝前举，再展示120秒自然动作的视频开头与中段；需要放大时用播放器全屏按钮。]

先看几段没有参与对应模型训练的视频。这里既有挥手、交替抬臂，也有双臂前举和屈膝配合，还有一分钟和两分钟的连续动作。每个窗口左边是真人输入，右边是模型驱动的机器人实际执行。八段都使用48段训练的同一个联合模型，以GVHMR作为人体前端，通过SONIC控制接口驱动机器人。

这些片段按动作类型集中展示，便于观察局部姿态、身体移动和动作转场。后面我会解释模型怎样把真人和机器人两种输入连接到共同空间，并用完整评价集合和消融说明效果来自哪里。

1. Main Contribution：人类与机器人共享的可执行运动空间（2分钟）

[停留在首页贡献句与完整Pipeline图，先指向两条输入，再指向汇合处。]

这项工作想建立一个共同的运动接口：让真人视频和机器人视频都能表达为同一类机器人可以执行的命令。我们的核心贡献，是学习不同观测到SONIC控制空间的映射，使固定模型处理新视频时，可以省去逐视频的人体到G1显式重定向。

动作里有两类信息值得分开处理。一类是视频中想做什么，例如抬手、慢跑、向左侧移；另一类是机器人此刻处于什么姿态、脚在哪里接触地面。我们让感知模型负责提取运动信息，让已有的低层策略结合机器人实际状态负责执行，中间通过共享命令连接。

[沿图走一遍。]

真人视频先经过冻结的GVHMR，恢复人体全身姿态和根运动，再由我们训练的运动时序编码器得到表示。机器人视频经过VideoMAE和LoRA适配。两条入口汇入同一个命令头，经过固定量化形成64维SONIC命令。低层策略读取命令和机器人自己的状态，输出29维动作，最后由PD和物理接触产生运动。

训练数据来自MoVi同步视频和动捕：动捕离线制作G1参考，teacher执行后留下共同命令标签和机器人视频。内部跟踪评估按参考首姿态初始化。这些设置使我们可以把两个域放到同一时间、同一执行接口下比较。

[播放全身运动模型的行走换向，约8秒。]

左边是真人输入，中间是teacher评分参照，最右边才是模型驱动的Student。请看它实际的摆臂、步态和换向。接下来我会用三组实验说明：共同空间如何建立，人体运动入口为什么有效，以及实际身体反馈怎样改善世界运动方向。

2. 六段配对动作：把共享空间训练出来（3分钟）

[展示六动作卡片和训练设置，先不读结果表。]

先把问题缩到一个可以明确检验的小集合：同一套网络能不能同时拟合真人和机器人两种画面？这里固定六段训练动作，反复抽取其中的时间窗口。六段是行走、慢跑、伸展、抛接、侧移和打电话，来自MoVi五位人物。实际物理评分时长分别约11.26、10.06、4.94、7.56、7.58和8.56秒。

每个动作有两种同步画面：真实人物视频，以及teacher执行同一动作后渲染的机器人视频。同一时刻的两种画面对应同一个SONIC命令目标，因此模型有明确的跨域对应关系可以学习。

[指向“每步四个锚点、两域配对”的示意。]

具体训练方式是六段轮流出现，每步从当段有效位置随机抽四个时间锚点。每个锚点读取八个历史位置的视觉信息，预测后续五个控制子步。总共12,000次更新，所以每段被选中2,000步，反复覆盖这段动作的不同时间窗口。联合训练时，同一组四个锚点分别读取真人和机器人画面，两域损失等权相加。

对照有三种：只训练机器人、只训练真人，以及两域联合训练；每种做两个随机种子。相同seed从同一个机器人预训练头开始，预训练头已有1,000步机器人监督。基础VideoMAE保持固定，训练末四层LoRA和完整视觉命令头；SONIC低层策略和PD也固定。优化目标就是标准化连续命令误差，这组实验没有额外action或表示对齐损失。

三个模型每个域的采样表和曝光量相同。联合模型一次更新同时看两个域，因此总域曝光是单域模型的两倍。这个设置回答的是共同网络能否容纳两域。

[切到结果表，只读跨域与Joint两组关键数。]

只在一个域训练，切换外观后关节误差约为0.247弧度；联合模型在真人和机器人输入上分别达到0.02884和0.02803弧度。每格是六段乘两个种子，共12次实际物理执行，均完整跑完。

[并排播放真人抛接与机器人抛接，共约16秒。]

这里两段输入使用同一个联合模型。Student先从视频预测命令，再以自己的状态连续执行动力学；它不是评分参照的轨迹回放。这个结果建立了双域共同命令的可拟合性。稍后讨论的全身运动模型在人类侧采用专门的感知入口，继续共享的是命令头和控制后端。

3. 数据怎样形成可比较的训练对（1分钟）

[展示“真人视频＋同步动捕→G1参考→teacher执行→机器人RGB及标签”的数据图。]

选择MoVi的原因是它同时有真人视频和同步动捕，可以明确知道两种画面是否对应同一个动作时刻。机器人视频由我们通过teacher执行产生。处理时使用物理时间对齐视频、动捕和控制记录；训练窗口取两种输入和命令标签共同有效的范围。

数据先按人物和原始录制划分，再切动作实例。六段实验用于共同空间拟合；全身运动入口比较使用32段训练动作；扩展模型增加到48段。开发评估分为12段移动相关视频和43段额外动作，人物都与本轮训练隔离。我们在后面的统一泛化章节把动作、人物、来源和时长逐项展开。

这里“动作实例”“原始录制”和“人物”分别计数。一段录制切出多个窗口可以增加动作覆盖，但人物数仍按真实来源统计。

4. 为什么采用这样的感知模块（2.5分钟）

[指向人体运动入口，展开145维构成。]

人体侧首先保留完整运动信息。145维中，126维表示21个身体关节的6D旋转；其余部分表示局部速度、相对高度、转向、根旋转和六点静止概率。这样，模型同时看到四肢动作和身体怎样移动。

随后用16个时刻的运动序列预测命令。同一个抬手姿态可能处在上升或下降过程，时序提供方向和相位。这个编码器采用两层Transformer，将145维投影到128维，再与机器人侧的表示对接。GVHMR固定，我们训练的是怎样把它恢复的运动转换成控制命令。

[指向机器人RGB入口。]

机器人侧保留视频编码。短窗捕捉局部变化，长窗提供动作阶段；末四层LoRA提供适配容量。视觉特征同时保留绝对值和相对静态首帧clip的变化，再由空间query读取相关区域，用八个锚点组织时间信息。这里的差分就是与静态参照比较，空间query则由训练学习关注位置。

这些选择各有明确的信息作用。完整系统实验回答它们组成的网络能否工作；要判断窗口、query数量或LoRA容量分别贡献多少，我们用替换模块后重新训练的对照来回答。

[展示RGB、全身运动＋RGB、全身运动入口三组表。]

这组实验最直接地回答人体该用什么入口。三个模型从同一个父模型出发，使用相同32段训练数据、相同时间采样和12,000步更新，机器人侧都继续读RGB。

在同12段开发视频上，全身运动入口将关节误差从0.1310降到0.0986弧度，世界身体点误差从423.82降到289.36毫米，约改善31.7%；速度误差从0.260降到0.177米每秒。将全身运动直接作为人体入口，比这次简单叠加RGB支路更有效。结果支持了我们的核心思路：先从人体视频形成运动观测，再学习到共同控制接口。

[播放同源RGB与全身运动的行走换向，再播放一段慢跑，共约20秒。]

行走片段里，实际路程从0.97米增加到2.40米，参考为2.81米。可以同时看摆臂、方向和地面上的推进。表格汇总完整12段，视频帮助解释误差对应的运动现象。

5. 为什么共享SONIC命令与低层控制（1分钟）

[指向共享头、FSQ、decoder和PD四个相邻模块。]

共享命令接口让人体运动和机器人画面可以利用同一种控制能力。命令头每次输出五条连续命令，经固定FSQ量化后，每条是64维。它们按50Hz依次送入SONIC，连接10Hz的视频命令更新与更快的控制执行。

SONIC同时读取930维本体历史，其中有关节角、关节速度、局部角速度、投影重力和上一动作。它根据当前身体生成29维动作，再转换为PD目标。机器人根部是浮动基座，前进或侧移必须通过腿部运动与地面接触形成，所以关节相似和世界路径相似需要分别衡量。

这一工作复用了SONIC的运动接口和控制能力。我们要学习的是新观测怎样进入这个接口，以及执行方向怎样与机器人实际状态对应。

6. 训练目标怎样对应研究问题（1分钟）

[指向域损失公式，再指向可训练/冻结图例。]

全身运动模型采用监督训练。共同命令损失要求两种输入预测同一时刻的teacher命令；机器人分支也持续给共享头和视觉适配器提供梯度。前端三模型比较使用真人损失加0.5倍机器人损失，并保留运动辅助项。

运动辅助项让中间表示关注速度、高度和转向等信息。这里GVHMR的全身运动是输入，teacher命令是输出监督，二者角色不同。低层控制器保持固定，监督损失不穿过物理仿真；执行质量由训练后的独立rollout检验。

六段拟合、全身入口比较和后续根运动续训各自采用固定配置。表中的模型名称直接描述变化条件，便于判断一个结果究竟来自输入、损失、训练覆盖，还是部署反馈。

7. 模块对照：信息怎样进入共同命令（1.5分钟）

[先指向联合训练保持机器人能力的两种子表，再切到正常/反序/置零输入。]

较大RGB模型中，两次独立训练都显示加入机器人域梯度能够保持机器人输入能力：仅真人训练的机器人关节误差约0.305弧度，联合训练约0.126弧度。这一结果解释了联合监督对共享接口的作用。

再固定同一个模型，把16个输入时刻反过来，世界误差从289.36增加到401.55毫米。将输入置零有三段发生跌倒。它说明模型使用了运动内容和时间顺序。接下来可以把身体旋转、根运动和静止概率分组干预，进一步定位信息来源。

后续五项训练对照也采用描述性名字：继续训练、固定共享接口、加强根运动监督、输入增强，以及组合方案。它们从同一个全身运动父模型增加6,000步，训练来源与采样一致。组合方案在12段上世界误差为269.68毫米；扩展到48段动作的模型为261.02毫米。这样，结构、监督和动作覆盖分别都有明确

的比较对象。

8. 实际朝向反馈：让命令跟随身体状态（1.5分钟）

[用图示区分“视频想去的方向”与“机器人当前朝向”，再显示反馈开关表。]

共同运动命令还需要匹配当前身体状态。SONIC的朝向语义与编码时身体朝向有关。假设视频要求向前走，机器人已经偏转了一个角度，继续发送原来数值可能带来不同的世界运动方向。因此我们将视频估计的相对朝向与机器人实际yaw结合，变换命令后再送入低层策略。

这里固定同一个神经网络，变化的是部署时是否打开朝向反馈。全身运动模型在12段视频上的朝向误差从20.54降到3.94度，XY误差从0.247降到0.191米，速度误差从0.177降到0.141米每秒。再打开既有训练集确定的1.4动态增益，XY误差为0.176米。

[播放同模型反馈前后约10秒，指向机器人行进方向。]

这个实验直接说明，视频运动表示与实际身体反馈可以在同一命令空间中配合。前端提供要做的动作，部署变换处理当前朝向偏差，低层策略负责接触和平衡。页面中的反馈结果按模型单独列出，扩展动作模型的结果对应其实际登记条件。

9. 泛化：把人物、动作、来源和时长放在同一张图里（2分钟）

[展示内部MoVi、外部HuMMan、自然长序列三个并列面板。]

泛化验证从三个方向展开。首先是内部MoVi。12段开发视频重点看移动和方向，额外43段覆盖更多非移动动作。两组与本轮梯度训练隔离，但已有研究使用历史，因此我们保持固定面板逐项比较。

动作覆盖实验从32段扩到48段，和保持32段的继续训练模型都增加6,000步。在43段额外验证上，扩展动作模型的关节误差从0.1522降到0.1238弧度，世界身体点误差从67.44降到60.97毫米，两个模型都43段完整。这说明扩大训练动作覆盖为共享空间带来了可测量的收益。

[播放扩展模型侧移约12秒。]

其次是外部HuMMan，用固定的全身运动父模型和扩展动作模型观察新人物、衣着、动作与拍摄条件。首批48个视频是累计120个视频的子集，页面按快照显示已经执行多少、完整多少、是否发生跌倒。人物数和动作ID按数据来源单独统计。

第三是自然长序列。三段MoVi原录制分别取30、60和120秒窗口，使用固定站姿一次初始化，再连续执行。较长窗口包含较短窗口的时间范围，因此它们提供的是时长变化下的行为观察。

外部与自然长片没有同步全长G1参考，所以这里看完整率、跌倒、低速比例、实际路径和接触脚速。有参考的短片回答跟踪有多准，长片回答动作怎样衔接、是否稳定、状态怎样积累。后续再通过同步参考或动作一致性评审，把外部模仿质量量化起来。

10. 指标怎样对应可观察的动作（1分钟）

[选择一个移动案例，依次高亮关节、世界点、root和接触指标。]

关节RMSE回答身体姿态是否接近。世界MPJPE同时包含身体姿态、朝向和位置变化；去根平移版本更集中地观察身体形态。Root XY、heading和路径长度分别看位置、方向和推进量。速度与加速度则反映动态变化。

接触F1描述接触时段是否与teacher一致，接触时脚部速度描述足部运动。它们测量不同现象，因此分别报告。完整率说明是否持续执行到输入结束，跟踪误差说明执行内容与参考的接近程度。

所有内部数值都来自G1的实际执行轨迹，使用固定身体点集和50Hz评分时钟，先逐片计算再等权汇总。这样，每个数字都能回到视频中的一个明确问题。

11. 推理效率：把成本放到相应环节（1分钟）

[展示从原始视频到命令、再到物理执行的分段时间图；查看页面快照分母。]

推理成本分为视频感知、学习式命令适配和控制执行。运动观测已有缓存时，命令适配很轻：CPU每100毫秒锚点平均约1.45毫秒；SONIC加PD和MuJoCo每20毫秒tick平均约10.93毫秒。

完整视频处理还要计入GVHMR。页面新增同一A40、同12个原始视频、计划三次重复的实测，每次都统计前端、命令生成和物理执行，按已完成配对数汇总。它帮助定位计算时间主要花在哪一部分。全身运动入口带来的执行质量和视频恢复的成本一起呈现。

这里采用全视频恢复，输入窗口还包含半秒未来信息，因此汇报的是离线视频到运动执行的效率。下一项比较将统一输入与后端，对学习式适配和显式重定向分别测量总处理时间，再计入一次训练成本。

12. 推理免重定向具体发生在哪里（45秒）

[高亮图中“人体运动→学习式适配→SONIC”路径，收起训练数据图。]

回到开头的贡献。固定训练完成后，新视频经GVHMR恢复人体运动，再直接由学习式适配器生成SONIC命令。这条命令生成路径省去逐片人体到G1关节轨迹的显式重定向步骤。

我们也检查了计算依赖：在一段行走输入上，将teacher目标置为无效值，预测命令逐位保持一致；保留初态和预测token后，移除未来参考，短程实际执行轨迹也保持一致。这个检查对应命令生成和控制执行各自真正读取的信息。内部跟踪评价与外部固定站姿运行采用各自明确的启动设置。

13. 扩展：视角、原生控制与视觉奖励（1分钟）

[依次指向跨视角表、原生控制链和视觉奖励示意。]

同一个动作换镜头，会改变图像中的身体外观。在第二机位的16段视频上，两机位训练将关节误差从0.2013降到0.1732弧度，约改善14%。这是RGB模型的视角训练结果；下一步检验全身运动入口如何进一步帮助视角迁移。

原生控制路线则验证另一套视觉命令与后端的配合：它使用256维表示、配套扩散控制器，Direct和Flow是两个视觉预测头。它与SONIC路线的表示、状态和控制器同时变化，因此按完整系统理解这组比较。

未来的视觉奖励方向，会把真人动作和机器人渲染映射到运动表示，先检验距离是否能区分方向、相位和原地踏步，再用实际执行质量优化命令残差。这让共享空间从命令预测进一步服务于执行优化。

14. 结束与资料定位（30秒）

[返回贡献句或完整Pipeline图。]

这项工作建立了从人体运动和机器人视频到共同SONIC空间的学习式接口。六段配对实验说明两种外观可以共享命令；全身运动入口改善了未参与本轮训练人物的执行；实际朝向反馈进一步把运动方向与机器人身体状态连接起来。扩展动作和多来源长序列验证，正在检验这个接口能够覆盖怎样的运动范围。

讲稿、逐片结果、训练设置和视频来源都可以从页面资料区直接查看。谢谢。

讲者速查：模型名字与复现键（不口播）

口头名称	实验含义	复现键
RGB共同空间模型	真人与机器人共用RGB入口	六段R/H/J；r37_rgb
全身运动共同空间模型 / 父模型	真人GVHMR运动入口、机器人RGB入口，共享命令	r37_gv_only
继续训练对照	保留32段覆盖，增加6,000步	r38_A_continue
固定共享命令接口	冻结末端命令及运动到命令输出模块	r38_B_freeze
加强根运动监督	增加运动辅助项和指定root分量权重	r38_C_root
运动观测增强	轻微输入噪声、局部时间遮罩与插值	r38_D_aug
固定接口＋根运动＋观测增强	三项修改组合	r38_E_combo
扩展动作模型（48段）	32→48段训练覆盖，同父模型增加6,000步	r38_F_expand48

A、B等字母对应上表实验条件。GV-only说明真人输入形式；human-only说明训练域，两者含义不同。原生表示与SONIC是两套执行后端；Direct与Flow是原生视觉头的候选形式。

讲者速查：六段复现设置（不口播）

六段完整来源ID、原始动作时长、评分时长、496个有效锚点分布、逐seed结果与代码路径见narrative-overfit.json。R/H/J种子为2026101801、2026101802；每步4锚点、每锚点5命令；J每域48,000次锚点曝光、240,000条命令监督。固定采样表让每段恰好轮到2,000步。初始化为同seed机器人P0头、基础VideoMAE权重和零有效增量LoRA；AdamW两组学习率1e−4。

实际训练对象为98,304个LoRA参数及715,456个head参数；标准化pre-FSQ MSE，J域内取均值后两域求和；无额外action、alignment、目标差分和旧机器人replay。物理起点为参考首qpos、qvel=0，首姿态预热10个控制tick；之后SONIC每20ms根据Student本体历史更新动作。评分参照为同后端teacher实际轨迹。

主要实验数值来源：全身运动入口、根反馈与扩展动作、网站最新固定快照。